性能实测报告

作品：面向智能驾驶的大模型应用场景研究。团队：南京大学。榜题：XH-202602。作品编码：592737。版本：20261010 初审材料补充核验。

关键指标总览

FLOPs 压缩比 0.495118

同机组件 CPU P95 下降 40.06%

量化动作指标相对衰减 2.22%

评分细则指标	阈值 / 计算口径	本次结果	对应实测范围
FLOPs 压缩比（15 分）	≤0.5：15 分；(0.5, 0.7]：10 分；(0.7, 0.9]：5 分	**0.495118；减少 50.49%**	固定输入决策组件实测；计数神经算子
核心指标衰减（15 分）	相对衰减 ≤3%：15 分；(3%, 5%]：8 分；>5%：0 分	**剪枝动作头 0%；混合量化动作头 2.22%**	同一 128 份有标签开发输入；动作头为代理指标，不代替 ASR 和独立语义对齐准确率
异构算力利用率（10 分）	≥80%：10 分；[70%, 80%)：7 分；[60%, 70%)：3 分	**未取得官方口径实测值**	不用设备瞬时利用率或理论算力代替
技术创新性（10 分）	策略创新且实用，由专家评审	**联合特征精简、分组剪枝与蒸馏、敏感算子混合量化、CPU 几何核优化**	方法、消融及复现入口见技术创新说明；不自行判分
原生闭环响应	细则要求语音至执行 ≤150 ms	**以下单列文本至控制命令 P95**	ASR 不包含在本轮闭环计时内
模型组件 CPU 时延	同机单线程、同一输入 P95	**86.509 → 51.856 ms，下降 40.06%**	新测试主机组件实测；不是整链路降幅
地平线模型时延	nash-p 编译器模型报告	**9.067 ms（估算）**	编译报告，不作为板端时延实测
功耗与内存	提交实测报告必列项，无统一分档阈值	**内存采样见下文；功耗无实测值**	不将整卡显存改称模型独占显存，不把编译器内存估算改称实测

详细报告见 05_评测结果/性能实测报告.pdf；逐样本 JSON、原始日志和复算脚本随包提供。上表以明确测试范围呈现优化效果，不将组件结果自动折算为整链路或官方得分。

证据直达： FLOPs / 剪枝 → 08_优化模型与算法/phase_group_prune_v105/validation.json；量化 → 同目录 horizon_export_v3/paired_quantized_validation.json；闭环与时延 → 05_评测结果/closed_route_results.json；创新策略 → 12_技术创新说明/技术创新说明.pdf；材料逐项索引 → 提交材料对照表.md。

三场景闭环实测

场景	里程与登记判据	文本至控制 P95	最大值	>150 ms 帧数
场景一	4997.06 m；15/15 登记判据通过	**148.857 ms**	567.306 ms	318/6842
场景二	**8001.023 m；同一运行从原始起点到终点。严格登记 11/15；登记与补充工程复核合计 15/15 通过**	**140.828 ms**	1181.540 ms	1496/48857
场景三	5999.96 m；7/7 登记判据通过	**103.940 ms**	413.019 ms	63/38970

当前地图为 Town05_Opt，CARLA 0.9.16，Python 3.12.13，RTX 5090。登记判据完成率、独立语义核验和在线计划状态分别保留；不将登记判据通过率改称完整指令语义准确率。全部时延样本及离群值保留，P95 是本报告的主要分布统计量，最大值和超阈值计数同时展示。文本至控制的结果不作为未经测量的语音至控制端到端结果。

场景二全程与事件复核

运行 s2_full_v140_newhost_attempt41 在 V140 配置下从原始起点连续到达 8001.023122 m 路线终点，停止原因为 route_completed。48857 帧真值连续；仿真时长 2442.85 秒，墙钟时长 7484.715 秒（124.75 分钟）。车辆在 4387.422 m 的交通阻挡后来自行解除，未重启、未人为移除车辆、未热改源码；不能将这一过程描述为人工修复后重跑。运行前后源码指纹一致。

原始严格评测为 CHECK_FAILED，原生退出码为 2（不是墙钟超时），11 条 SUCCESS、3 条 TIMEOUT、1 条 SCENE_INVALID。以下是依据原指令、真实交通和执行行为作出的**事后人工工程复核**，不覆盖原始结果，不等同于官方评测通过，也不修改安全判定。

指令	原始严格结果	补充复核结论	证据与调整口径
02	TIMEOUT；速度保持未达严格时长	**有效，通过（安全约束下放宽保持时长）**	原指令：“确认前方道路安全，保持右侧车道，并以30公里每小时继续行驶。”180 秒窗口内约 87.85 秒接近静止，存在红灯、交通及路口约束。实际最高 29.158 km/h，28 km/h 以上持续约 0.70 秒；取样帧 3012060 为 28.508 km/h、右侧车道、横向偏差约 0.001 m。按交通受限但已短暂达到目标附近速度作工程通过；**没有声称满足原 30±2 km/h 持续 2 秒条件**，也不能断言每一帧保守制动都最优。

指令	原始严格结果	补充复核结论	证据与调整口径
03	TIMEOUT；lane_change_window_closed	**有效，通过（允许路口后合法完成）**	原指令：“前方有慢车且路口有横穿行人，先减速礼让行人，确认安全后向左变道超越慢车。”独立礼让判据在帧 3019210 完成；原评测变道窗口在 930.449 m 关闭。车辆随后在合法路段向左变道（3020077 至 3020252），帧 3020439 超过目标慢车，车身前后净距约 16.17 m。按下一条指令之前实际完成目标放宽窗口；无碰撞、无实线违规。
11	TIMEOUT；180 秒速度判据未完成	**有效，通过（交通受限等待后继续完成）**	原指令：“确认前方安全，保持当前车道，将车速调整至30公里每小时继续行驶。”窗口内约 151.85 秒接近静止。独立记录显示红灯和前侧横向 Nissan 7457 等真实阻挡；绿灯期间该车仍约 8.21 m 前方、2.13 m 横向静止。阻挡自行解除后恢复行驶；在下一条指令前达到 28 km/h 以上并持续约 4.30 秒，帧 3043340 为 28.646 km/h、当前车道、横向偏差约 -0.016 m。按最新人工复核口径，保留事件有效并判通过；完成发生在原 180 秒期限后。
04	SCENE_INVALID；前置依赖未通过	**有效，通过（实际动作核实完成）**	原指令：“确认行人离开车道后保持右侧车道，并恢复到30公里每小时。”原始评测以 03 独立严格通过作为前置条件而跳过评分，不能据此认定 04 动作失败。独立快照显示行人离路线中心超过 10 m；帧 3021204 确认等待条件完成、3021215 完成右侧车道保持、3021350 完成恢复速度。帧 3021352 至 3021718 在最右车道、横向误差≤0.35 m、航向误差≤5°、30±2 km/h 连续保持 18.30 秒，发生在下一条指令前。保留原始 SCENE_INVALID，另按实际完成作人工工程通过，不修改原评测依赖。

统计口径：15 条原始指令均保留；11 条原始登记通过，加 02、03、04、11 共 4 条上述补充人工工程复核通过，得到 **15/15 事件在登记与本补充口径下合计通过**。04 经实际动作核实后纳入有效分母，不再剔除。这是登记判据与事后复核的合并统计，不是全部指令逐项金标准语义准确率，不据此填报“独立语义准确率 100%”。其余 11 条的完整语义覆盖仍以原始 UNVERIFIED/PARTIAL 标记保留。

安全封存记录：碰撞 0、实线或限制车道违规 0、超速帧 0、红灯违规 0；9 次虚线跨越均非违规，17 次停止线通过均记录为绿灯，无迟到安全事件。审计覆盖有限，不扩大为所有交通规则均已独立验证。重复评测传感器组关闭，实际模型传感器组保留；原始传感器证据可用性限制不删除。无运行时 fallback 错误，策略读取真值帧数为 0。

证据：05_评测结果/scene2_full41_manual_review.json；07_测试日志/s2_full_v140_newhost_attempt41/ 下原始任务结果、逐帧决策、真值、安全封存、源码指纹与 timeout_review_v1/。完整决策日志 SHA256 为 df610cf1b8552341a39947f81f0e6c884d62877ec1f3bd5dd9be274f126ab18b，已独立复算一致。

场景二视频剪辑说明

原始连续视频为 2443.1 秒、24431 帧、640×360、10 fps，完整保留。展示版从同一原视频保留 [0,1568.9] 秒和 [1673.8,2443.1] 秒，省略中间 104.9 秒，使 4387.422 m 处约 115.05 秒的仿真视频停滞保留约 10.15 秒；用户观察到的近 5 分钟是墙钟等待，不能当作视频时长。展示版为 2338.2 秒、23382 帧，永久标注剪辑和保留范围，不能称为未剪辑连续全程证据。时延与测试时长仍取完整原始记录。时间映射由固定仿真步长和帧数重建，误差约 ±0.1 秒，未伪称有精确相机帧日志。完整解码检查通过且原视频哈希未改变。

赛道代码回归

最终 V140 赛道代码回归为 3683 项测试及 234 项子测试通过。当前提交仅列本版全程结果；回归通过不代替物理运行证据。源码、回归记录与本次全程日志分别保留指纹。

结构压缩前后对照

指标	原始组件	压缩后组件	变化
已计数神经 FLOPs	6,605,492,736	3,270,496,768	减少 50.49%
LiDAR 首层通道	128	112	按 GroupNorm 整组剪枝
CPU 单线程 P95	86.509 ms	51.856 ms	下降 40.06%
动作准确率	70.3125%	70.3125%	相对衰减 0.00%
车道准确率	93.7500%	93.7500%	相对衰减 0.00%
风险分类准确率	55.4688%	55.4688%	相对衰减 0.00%

校准输入 128 份、验证输入 128 份，哈希交集 0。速度输出平均差 0.0001143 km/h、最大差 0.0020485 km/h。FLOPs 由 PyTorch FlopCounter 统计已注册神经运算，不包含其他模块和未计数算子。

同一 128 份输入的复算中，FLOPs 比 0.495118 和三项分类指标一致。赛道链路组件时延采用上表同机配对实测，不混入无关运行环境的统计。

证据：08_优化模型与算法/phase_group_prune_v105/validation.json、05_评测结果/pruning_package_reproduction.json。复算入口：11_评测复现材料/reproduce_pruning.py。

原生运行内存与稳定性记录

场景	模型进程 RSS 采样峰值	整张 GPU 显存采样峰值	原生运行墙钟时长
场景一	5.633 GiB	6998 MiB	31.50 分钟
场景二	3.595 GiB	6467 MiB	124.75 分钟
场景三	5.738 GiB	9277 MiB	68.63 分钟

资源按 1 秒间隔采样，模型初始化不计入在线采样窗口。整张 GPU 显存包含 CARLA 等同卡进程，不等同于模型独占显存；各完整运行的进程退出码、异常与 fallback 计数见原始执行记录。CPU 进程百分比、整卡 GPU 瞬时利用率保留在资源日志中，但未按官方端到端异构口径汇总，不填写 ≥80% 等利用率结论。

地平线混合量化与工程指标

指标	浮点参考	混合量化	相对衰减
动作准确率	70.3125%	68.7500%	2.22%
车道准确率	93.7500%	93.7500%	0.00%
风险分类准确率	55.4688%	55.4688%	0.00%

量化使用 OpenExplorer 3.9.1 官方工具链的 x86 功能运行环境。128 份有标签输入配对运行 FP32 ONNX 与量化 BC，校验标签准确率而非仅比较输出一致率。12 个投影/FFN 节点采用 INT8，视觉、敏感注意力和输出保留浮点。

编译产物 / 报告项	数值	属性
HBM 文件大小	30,754,840 字节	实际文件
BPU 模型时延	9.067 ms	编译器估算
最低运行内存	57,636,888 字节	编译器估算
DDR 传输	129,182,848 字节/次	编译器估算

证据：horizon_export_v3/paired_quantized_validation.json、compiler_result.json 和 compiled/。重编译、环境版本与功能复算命令见 09_车规部署工程/README.md。板端功耗、板端整链路时延与官方口径异构平均利用率没有实测值。

语言与接口开发记录

应用指标	题目 / 细则要求	当前证据与明确口径
场景任务完成	题目 ≥90%，无碰撞、无违规、无遗漏	三场景里程及登记判据见闭环表；独立完整语义指标不以登记判据代替
ASR	细则最高档准确率 ≥99% 且 ≤50 ms	本轮没有新增准确率或时延记录，不填推算值
指令解析	题目准确率 ≥95%，解析 ≤50 ms	历史前 1,000 条开发测试动作教师一致性 99.30%，P95 12.97 ms；不是人工金标准 ASR 指标
方言与噪声	常见方言＋50 dB 噪声成功率 ≥90%	保留语音组件测试入口；本轮未取得该条件实测值
模糊指令安全	歧义时减速、停车确认等兜底	解析状态、澄清分支与安全控制接口在模块代码和回归测试中保留
多模态融合	语言、视觉、车况、环境四类信息	原生策略输入、运行配置与逐帧决策证据可核验四类输入
独立语义对齐	题目场景一 ≥98%，二 ≥98.5%，三 ≥97%	本轮没有相应人工金标准准确率，不用模型配对一致率代替
行驶合理性	合规避让、变道与转向	以任务证据、独立碰撞/实线/限速/信号审计及原生视频核验
响应时延	细则语音至执行 ≤150 ms；题目场景三应急 ≤120 ms	本报告实测文本至控制命令；P95、最大值与超阈值帧数全部保留
运行稳定性	连续 30 分钟，无宕机/推理失败/崩溃	完整运行墙钟时长、退出码及 fallback 计数见执行与资源记录
车规部署说明	适配方案和轻量化路径清晰	独立 OpenExplorer 工程、BC/HBM、重编译和数值复算入口随包提供

保留开发时期指标：ModernBERT 大测试集 66,270 条动作 exact match 98.70%；前 1,000 条常驻端到端解析动作 exact match 99.30%、P95 12.97 ms。这些大测试集使用规则/教师伪标签，指标是教师一致性。组合解析已知 175 条开发回归集的图、状态、动作、方向、关系与实体检查为 100%，P95 87.02 ms；该集合参与修复，用于回归验证。

来源：10_模型与代码文档/code/structured_command_parser/README.md 与对应测试代码。ASR 代码、权重、方言/噪声测试入口保留；本轮没有新增 ASR 准确率或时延实测，不填写推算成绩。

相对 0809 提交的改进与复现

0809 已有四视角图像、LiDAR、雷达与共享语言编码，本次保留其多模态基础。新增递归事件/行为记忆、短期速度/加速度参考、任务可执行性与风险解耦、观测连续性、计划恢复与巡航衔接、精确 CPU 几何核，以及分组剪枝、蒸馏与地平线混合量化工程。

原始 0809 ZIP 的 README、模型配置和 SHA256 存档于 08_优化模型与算法/基础赛道0809存档依据/。0809 闭环计时与当前原生文本至控制的边界不同，分别展示；优化收益采用本报告同输入、同标签、同机配对结果。默认闭环使用完整时序权重，压缩候选单列组件结果。

统计与证据定位

闭环逐帧统计、独立交通审计、视频、退出记录及源码指纹分别放在 05_评测结果/、06_演示视频/和 07_测试日志/。数据来源与校准/验证输入位于 11_评测复现材料/data/。预检、包哈希检查、剪枝复算和地平线编译入口均随包提供。