

0908 任务分配

——挑战赛道技术路线与任务分工

1 挑战赛道要求概括

1.1 挑战目标与指定平台

挑战赛道在基础赛道能力之上，重点验证**模型轻量化、指定芯片适配、异构计算优化及性能保持**。根据晋级通知，统一采用**地平线 J6P**，支持先在 PC 端使用 X86 仿真调试，最终以 Docker 镜像提交。

本组沿用已经形成的模块化 VLA 链路，不重新训练大型端到端 VLA。继续使用现有 RTX 5090 服务器完成训练与 CARLA 联调，使用独立的 J6P 官方工具链完成量化、编译和仿真；板端时延、功耗、内存及利用率由 J6P 实机验证。以下按任务依赖组织，不安排具体日程。

1.2 核心要求与评分目标

维度	题目要求或高分目标	落实与统计方式
性能保持	核心性能下降不超过 3%	压缩前后采用同输入、同任务与同统计方法；继续满足基础场景最低要求。
推理响应	模型端到端推理不超过 200 ms	保留基础场景更严格的响应要求；逐请求测量，不只测单个网络。
计算量压缩	压缩后/原模型 FLOPs 不超过 0.5	通过结构与特征压缩降低计算量，量化位宽变化不直接视为 FLOPs 减半。
资源占用	功耗不超过 25 W，内存不超过 512 MB	统计实际运行功耗和峰值占用，不能用权重大小代替运行内存。
异构执行	对应评分档位利用率目标不低于 80%	依据真实有效负载测量调度效果，不增加无效运算来提高利用率。
验证与材料	同源评测、部署模型与 Docker	准备三场景 1000 帧代表性多模态数据及对照结果，保留优化和部署证据。

2 挑战赛道结构划分与人员职责

2.1 总体结构




图 1: 保留基础赛道链路，在原职责边界内开展轻量化与 J6P 适配。

2.2 人员职责总览

负责人	延续的工作方向	挑战赛道职责
朱善哲	指令解析、轻量 VLA、集成	语言与 Adapter 压缩、共享编码、公共 J6P 后端、版本整合和整体性能优化。
李畅锦	语音识别与预处理	ASR 轻量适配，驾驶语义、数字方向词、方言噪声和音频链路验证。
黄皓星	场景理解与语义对齐	视觉/BEV 压缩，候选实体与目标落地，感知侧导出、量化和精度验证。
王皓然	高层动作、风险门与 FSM	动作接口、时序安全、条件执行、异常降级和规则侧运行优化。
刘旭	CARLA、控制、日志与评测	同源数据、传感器回放、控制闭环、统一指标、板端资源测量与重复验证。

3 各负责人需要完成的任务

3.1 朱善哲：指令解析、VLA 优化与系统集成

- 优化 ModernBERT 与轻量 VLA，减少重复编码和计算开销，保持指令解析与决策能力。
- 完成语言和决策模型的 J6P 适配，协调各模块接口与整体联调。

参考路线：共享语言编码，结合蒸馏、结构压缩和量化进行优化，再比较精度与全链路性能。

3.2 李畅锦：语音识别优化

- 降低语音识别模块的资源占用与延时，保持驾驶指令识别效果。
- 检查方言、噪声以及方向、数字等关键信息，并与指令解析模块联调。

参考路线：先测试现有模型开销，再尝试量化或轻量模型替换，以驾驶语义保持为主要优化依据。

3.3 黄皓星：场景理解与语义对齐优化

- 优化视觉与 BEV 编码，降低感知计算量，保留关键目标和场景信息。
- 保持指令目标与场景实体的准确对齐，完成感知侧 J6P 适配。

参考路线：先量化现有模型，再按效果进行剪枝、蒸馏或特征缩减，结合下游决策验证优化收益。

3.4 王皓然：高层决策与安全控制优化

- 完善高层动作、风险安全门和 FSM，保证组合指令与条件指令正确执行。
- 保持连续决策稳定，处理危险建议、推理超时和感知异常等情况。

参考路线：延续现有决策架构，重点回归加减速波动、前车制动等问题，再优化状态管理和安全策略。

3.5 刘旭：仿真控制与统一评测

- 维护三类 CARLA 场景与控制链路，组织原版和优化版的重复对照测试。
- 配合 J6P 部署，测量任务效果、稳定性、延时和资源占用，定位系统瓶颈。

参考路线：使用同源数据回放和多次闭环测试比较效果，再通过 J6P 实机验证资源与运行性能。